Week 2

태그
열

Lecture 2 – Word Vectors and Word Senses

Word2Vec

- Word2Vec maximizes objectvie function by putting similar words nearby in space
- 벡터를 빼고 더하는 과정 등을 통해 단어에서의 의미 요소를 빼고 더할 수 있다.
  - Ex) king - man + woman = queen
- 2D space로 변환하는 과정에서 잃어버리는 맥락이나 정보가 있을 수 있다.

Optimization: Gradient Descent

- Minimizing cost function
- Gradient Descent is an algorithm to minimize cost function

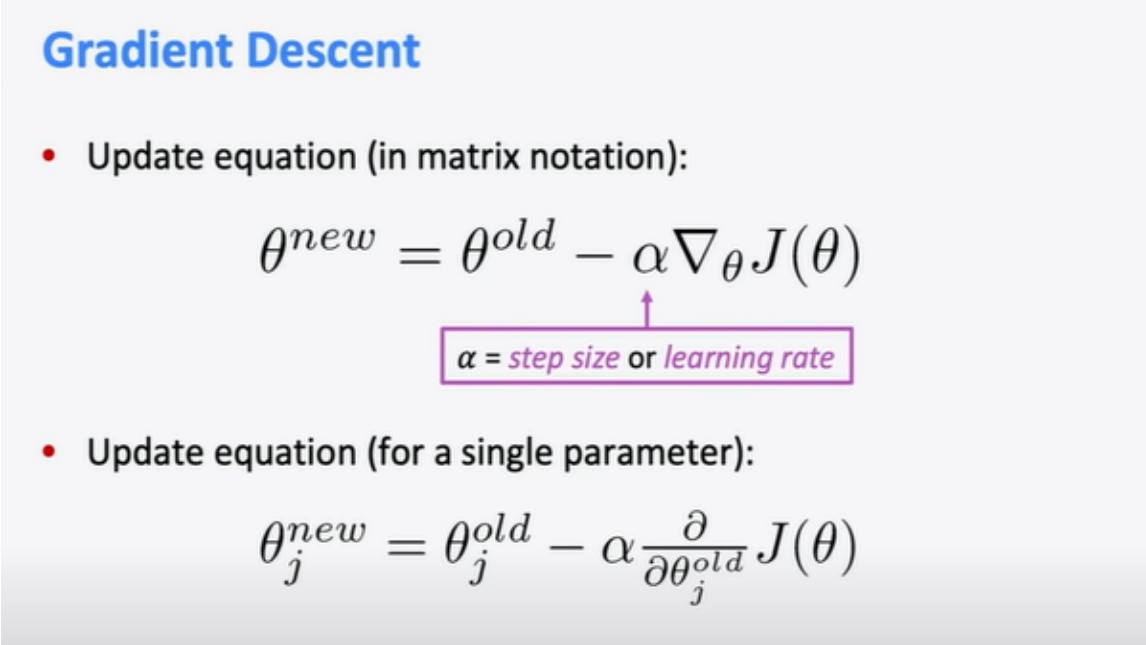

    - alpha 값이 너무 크면 한 번에 많이 하강하게 되므로 정확하지 않은 결과가 나올 수 있다. 따라서 조금씩 하강할 수 있도록 적절한 값을 찾는 것이 중요하다.
- 기존의 cost function은 corpus 내의 모든 window에 대해 계산하기 때문에 계산량이 너무 많다.
    - 해결방법: Stochastic gradient descent (SGD)
    - Repeatedly sample windows, and update after each one

Stochastic gradients with word vectors

- Iteratively take gradients at each such window
- But in each window, only have at most 2m + 1 words, so parameter update is sparse
- Therefore the goal is to update the word vectors that actually appear

Word2Vec: More details

Two model varients

1. Skip-grams (SG)

   : Predict context words given center words

2. Continuous Bag of Words (CBOW)

   : Predict center word from context words

- The skip-gram model with negative sampling
    - 기존의 방식에서 쓰인 normalization factor는 모든 단어에 대해 계산을 진행하므로 너무 느리다

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

    - 이를 해결하기 위해 negative sampling을 이용한다
    - 분모에서 실제로 관찰된 단어에 대해 하나의 `binary logistic regression`을 진행하고, 실제로 관찰된 단어에 높은 확률을 부여한다.

- 그 후 다른 여러 개의 단어를 랜덤하게 샘플링하는데 이를 `negative sample`이라고 한다.
- negative sample들은 실제로 관찰된 단어들이 아니므로 가능한 한 낮은 확률을 부여한다.

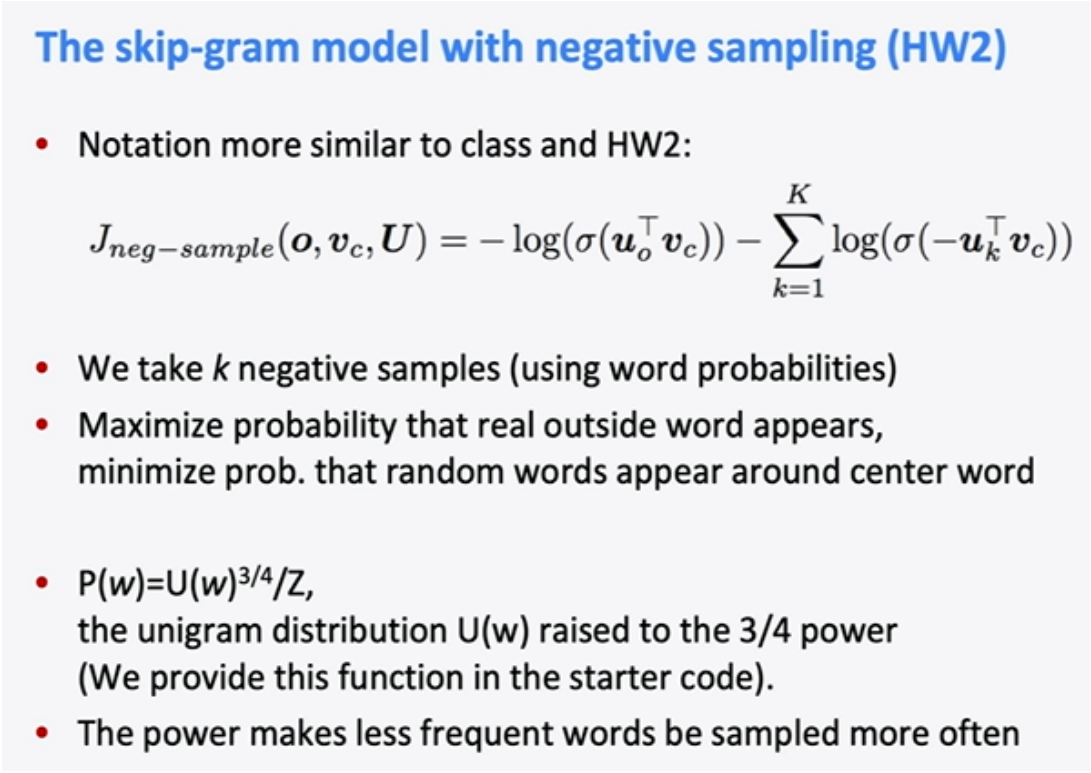

Co-occurence matrix (vector)

- 사이즈가 너무 커서 비효율적.
- 해결 방법
  - Dimensionality reduction

Count based vs. Direct prediction

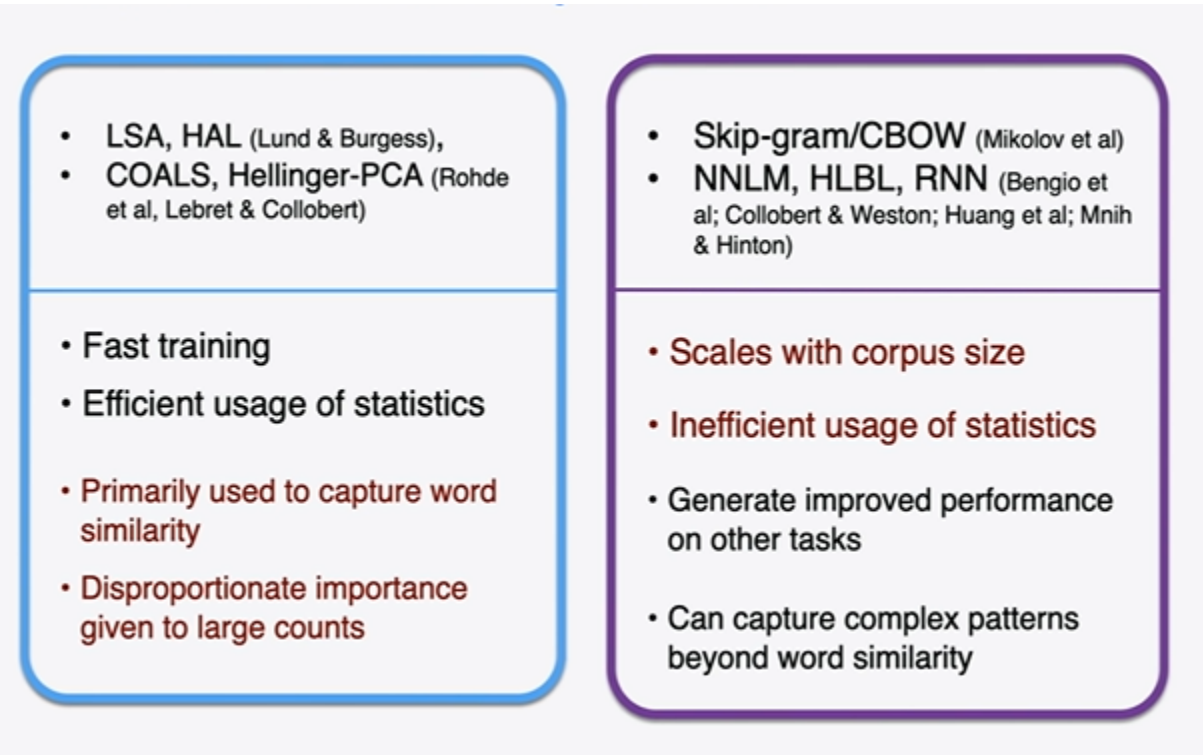

- 두 가지 방법의 장점을 결합한 방법인 **GloVe**도 있다.