CS231N 6강 Training Neural Networks

Activation Functions(활성화 함수)

:딥러닝에서 비선형성을 가해주는 역할을 함.


Sigmoid


$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

-10

tanh


tanh(x)





Leaky ReLU

 $\max(0.1x, x)$




Maxout

 $\max(w_1^T x + b_1, w_2^T x + b_2)$

ELU

$$\begin{cases} x & x \ge 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



Use ReLU. Be careful with your learning rates
Try out Leaky ReLU / Maxout / ELU
Try out tanh but don't expect much
Don't use sigmoid

Sigmoid

단점: 1)vanishing gradient 2)zero-center 3)exp의 연산 으로 activation 함수로 이용하지 않고 최종 output 낼때만 이용

ReLU


:기울기 소실 문제 해결, exp 연산 사라짐
But 입력값의 음의 부분은 전부 0으로 두어 vanishing gradient,zero-centered 문제가 여전히 있음

Dead ReLu

: reLu를 활성화 함수로 하는 모델에서 훈련 시 freeze 되는데 dead reLu에 빠진것

Leaky ReLu

: Dead ReLu 단점 보완(vanishing gradient 해결)



Maxout Neuron

: parameter을 더 두어서 출력 갑이 다른 2개의 함수 중에 max 값 선택하는 함수, 연산량 두배

Maxout "Neuron"

[Goodfellow et al., 2013]

- Does not have the basic form of dot product -> nonlinearity
- Generalizes ReLU and Leaky ReLU
- Linear Regime! Does not saturate! Does not die!

$$\max(w_1^Tx+b_1,w_2^Tx+b_2)$$

Problem: doubles the number of parameters/neuron :(

Data processing (데이터 전처리)

1)zero-centering

: 이미지 데이터는 픽셀 값이 같은 범위여서 zero-centering만 함, 입력값이 모두 양수이면 w 가 전부 음수나 양수가 되어 업데이트가 일방향으로 일어남 -> zero-mean


Remember: Consider what happens when the input to a neuron is always positive...

$$f\left(\sum_i w_i x_i + b
ight)$$

What can we say about the gradients on w?


Always all positive or all negative :(

(this is also why you want zero-mean data!)




Weight Initialization

- Weight가 모두 0이면 입력값에서부터 모든 뉴런이 같은 값만을 출력함(layer 의미x)
- 맨 처음의 weight에 임의의 작은 값 부여하기: layer이 깊어질수록 0으로 수렴함 , update 잘 안됨
- Initialization이 w이 작으면 collapse 되고, 너무 크게 되면 saturate 됨
- Xavier initialization



Batch normalization

- Batch normalization을 하면 weight normalization 안해도 됨
- Training과정에서 gradient vanishing 문제를 일어나지 않게 함
- 각 층의 input distribution을 평균 0/표준편차 1로 만드는 것
- Activation layer 전에 잘 분포되도록 함



Learning process

Preprocess the data -> choose the architecture -> loss check -> train with few examples -> hyperparameter select

Hyperparameter Optimization

- 넓은 범위 -> 좁은 범위
- Grid Search < Random Search
- Network architecture,learning rate, regularization 등이 있음
- Validation의 acc 값과 training acc 값 차이 크면 과적합 일어나서 조심해야함

