

Ch6. 차원 축소

01 차원 축소 개요


• 차원 축소 → 직관적 해석 가능, 데이터 고차

- 파라미터: 복제된 파라미터 제거, 주요파라미터 선택
- 파라미터: 함수적, 연속 특성 추출 → 잠재공간으로
- 이미지 변환: 압축, 디코딩을 위한 숨겨진 위치를

02 PCA

• PCA

: 여러 변수는 상관관계 있음 → 이를 대표하는 주성분을 → 차원 축소



- ① 입력 데이터셋의 공분산 행렬 계산
- ② 공분산 행렬의 고유값, 고유벡터 계산
- ③ 고유값 크순으로 k 개 (PCA 변환 회수 만큼)의 고유벡터 추출
- ④ 추출된 고유벡터를 이용해 입력 데이터 변환

03 LDA

• LDA: 선형판별분석법

- PCA와 유사
 - PCA: 입력데이터의 분산의 기능극대화
 - LDA: 입력데이터의 가장 큰 클래스 분리를 최대화하는 축

- ① 클래스 내부 분산 행렬 / 클래스 간 분산 행렬 구하기
 S_W (within) S_B (between)
 (입력 데이터의 가장 큰 클래스별 개체와의 표준편차 계산)
- ② $S_W^{-1} S_B = [e_1 \dots e_n] \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{bmatrix} \begin{bmatrix} e_1^T \\ \vdots \\ e_n^T \end{bmatrix}$
- ③ 고유값이 가장 큰 순으로 k 개 (LDA 변환 회수만큼) 추출
- ④ 추출된 고유벡터를 이용해 새롭게 입력 데이터 변환

04 SVD

• SVD: 특이값 분해 (정방행렬이 아니어도 적용 가능)

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V^T_{n \times n}$$

대각행렬

- Σ 의 대각행렬 중 0인 행 (+ 그에 대응하는 U, V 의 요소) 제거

$$A_{m \times n} = U_{m \times p} \Sigma_{p \times p} V^T_{p \times n}$$

- Truncated SVD:

Σ 의 대각행렬 중 상위 k 개만 추출 → 차원을 더 줄인 행렬

05 NMF

• NMF

: Truncated SVD 같은 낮은 행렬 근사법의 변형

$$V_{4 \times 6} \approx W_{4 \times 2} \times H_{2 \times 6}$$

- W : 값이 가는 행렬
 원본 행에 대해 잠재요소의 값이 얼마나 되는지
- H : 값이 많은 행렬
 잠재요소와 원본 행을 어떻게 구성했는지